



软件分析

# 课程介绍

熊英飞  
北京大学  
2018

# 软件缺陷可能导致灾难性事故



2003年美加停电事故：由于软件故障，美国和加拿大发生大面积停电事故，造成至少11人丧生



**事故原因：**电网管理软件内部实现存在重大缺陷，无法正确处理并行事件。

2006年巴西空难：由于防撞系统问题，巴西两架飞机相撞，造成154名人员丧生



**事故原因：**软件系统没有实现对防撞硬件系统故障的检测

2005年，东京证券交易所出现了人类历史上最长停机事故，造成的资金和信誉损失难以估算



**事故原因：**由于输入错误的升级指令，导致软件版本不匹配

# 能否彻底避免软件中出现缺陷？



- 问题：
  - 给定某程序  $P$
  - 给定某种类型的缺陷， 如内存泄露
- 输出：
  - 该程序中是否含有该类型的缺陷
- 是否存在算法能给出该判定问题的答案？
  - 软件测试
    - “Testing shows the presence, not the absence of bugs.” -- Edsger W. Dijkstra



# 库尔特·哥德尔(Kurt Gödel)

- 20世纪最伟大的数学家、逻辑学家之一
- 爱因斯坦语录
  - “我每天会去办公室，因为路上可以和哥德尔聊天”
- 主要成就
  - 哥德尔不完备定理



# 希尔伯特计划

## Hilbert's Program



- 德国数学家大卫·希尔伯特在20世纪20年代提出
- 背景：第三次数学危机
  - 罗素悖论：  $R = \{X \mid X \notin X\}, R \in R?$
- 目标：提出一个形式系统，可以覆盖现在所有的数学定理，并且具有如下特点：
  - 完备性：所有真命题都可以被证明
  - 一致性：不可能推出矛盾，即一个命题要么是真，要么是假，不会两者都是
  - 可判断性：存在一个算法来确定任意命题的真假

# 哥德尔不完备定理

## Gödel's Incompleteness Theorem



- 1931年由哥德尔证明
- 蕴含皮亚诺算术公理的一致系统是不完备的
- 皮亚诺算术公理=自然数
  - 0是自然数
  - 每个自然数都有一个后继
  - 0不是任何自然数的后继
  - 如果 $b, c$ 的后继都是 $a$ , 则 $b=c$
  - 自然数仅包含0和其任意多次后继
- 对任意能表示自然数的系统, 一定有定理不能被证明

# 哥德尔不完备定理与内存泄露判定



- 主流程程序语言的语法+语义=能表示自然数的形式系统
- 设有表达式T不能被证明
  - `a=malloc()`
  - `if (T) free(a);`
  - `return;`
- 若T为永真式，则没有内存泄露，否则就可能有



# 停机问题

- 据说哥德尔不完备性定理的证明和停机问题的证明非常类似
- 停机问题：判断一个程序在给定输入上是否会终止
  - 对应希尔伯特期望的第三个属性
- 图灵于**1936**年证明：不存在一个算法能回答停机问题
  - 因为当时还没有计算机，就顺便提出了图灵机





# 停机问题证明

- 假设存在停机问题判断算法: `bool Halt(p)`

- `p`为特定程序

- 给定某邪恶程序

```
void Evil() {  
    if (!Halt(Evil)) return;  
    else while(1);  
}
```

- `Halt(Evil)`的返回值是什么？

- 如果为真，则`Evil`不停机，矛盾
  - 如果为假，则`Evil`停机，矛盾

# 是否存在确保无内存泄露的算法？



- 假设存在算法： `bool LeakFree(Program p)`

- 给定邪恶程序：

```
void Evil() {  
    int a = malloc();  
    if (LeakFree(Evil)) return;  
    else free(a);  
}
```

- `LeakFree(Evil)`产生矛盾：

- 如果为真，则有泄露
- 如果为假，则没有泄露



# 术语：可判定问题

- 判定问题（Decision Problem）：回答是/否的问题
- 可判定问题（Decidable Problem）是一个判定问题，该问题存在一个算法，使得对于该问题的每一个实例都能给出是/否的答案。
- 停机问题是不可判定问题
- 确定程序有无内存泄露是不可判定问题



# 练习

- 如下程序分析问题是否可判定？假设所有基本操作都在有限时间内执行完毕，给出证明。
  - 确定程序使用的变量是否多于50个
  - 给定程序，判断是否存在输入使得该程序抛出异常
  - 给定程序和输入，判断程序是否会抛出异常
  - 给定无循环和函数调用的程序和特定输入，判断程序是否会抛出异常
  - 给定无循环和函数调用的程序，判断程序是否在某些输入上会抛出异常
  - 给定程序和输入，判断程序是否会在前50步执行中抛出异常（执行一条语句为一步）



# 问题

- 到底有多少程序分析问题是不可判定的？



# 莱斯定理(Rice's Theorem)

- 我们可以把任意程序看成一个从输入到输出上的部分函数（**Partial Function**），该函数描述了程序的行为
- 关于程序行为的任何非平凡属性，都不存在可以检查该属性的通用算法
  - 平凡属性：要么对全体程序都为真，要么对全体程序都为假
  - 非平凡属性：不是平凡的所有属性
  - 关于程序行为：即能定义在函数上的属性

# 运用莱斯定理快速确定可判定性



- 给定程序，判断是否存在输入使得该程序抛出异常
  - 可以定义： $\exists i, f(i) = EXCPT$
- 给定程序和输入，判断程序是否会抛出异常
  - 可以定义： $f(i) = EXCPT$
- 确定程序使用的变量是否多于50个
  - 涉及程序结构，不能定义
- 给定无循环和函数调用的程序，判断程序是否在某些输入上会抛出异常
  - 只涉及部分程序，不符合定理条件（注意：不符合莱斯定理定义不代表可判定）



# 莱斯定理的证明

- 反证法：给定函数上的性质 $P$ ，因为 $P$ 非平凡，所以一定存在程序使得 $P$ 满足，记为 $ok\_prog$ 。假设检测该性质 $P$ 的算法为 $P\_holds$ 。

- 编写如下函数来检测程序 $p$ 是否停机

```
Bool halt(Program p) {  
    void evil(Input n) {  
        Output v = ok_prog(n);  
        p();  
        return v;  
    }  
    return P_holds(evil);  
}
```

- 如果 $P\_holds$ 存在，则我们有了检测停机的算法





刚刚说的都是真的吗？  
世界真的这么没希望吗？



# 一个检查停机问题的算法

- 当前系统的状态为内存和寄存器中所有Bit的值
- 给定任意状态，系统的下一状态是确定的
- 令系统的所有可能的状态为节点，状态A可达状态B就添加一条A到B的边，那么形成一个有向图（有限状态自动机）
- 如果从任意初始状态出发的路径都无环，那么系统一定停机，否则可能会死机
  - 给定起始状态，遍历执行路径，同时记录所有访问过的状态。
  - 如果有达到一个之前访问过的状态，则有环。如果达到终态，则无环。
- 因为状态数量有穷，所以该算法一定终止。

# 哥德尔、图灵、莱斯错了吗？



- 该检查算法的运行需要比被检查程序p更多的状态

```
void Evil() {  
    if (!Halt(Evil)) return;  
    else while(1);  
}
```

- Halt(Evil)无法运行，因为Halt(Evil)的运行需要比Evil()更多的状态空间，而Evil()的运行又需要比Halt(Evil)更多的状态空间
- 然而一般来说，不会有程序调用Halt
  - 对这类程序该算法可以工作



# 模型检查

- 基于有限状态自动机抽象判断程序属性的技术
- 被广泛应用于硬件领域
- 在软件领域因为状态爆炸问题（即状态数太多），几乎无法被应用到大型程序上

# 所以，世界还是没有希望了吗？



- 近似法拯救世界
- 近似法：允许在得不到精确值的时候，给出不精确的答案
- 对于判断问题，不精确的答案就是
  - 不知道




# 近似求解判定问题

- 原始判定问题：输出“是”或者“否”
- 近似求解判定问题：输出“是”、“否”或者“不知道”
- 两个变体
  - 只输出“是”或者“不知道”
    - must analysis, lower/under approximation（下近似）
  - 只输出“否”或者“不知道”
    - may analysis, upper/over approximation（上近似）
- 目标：尽可能多的回答“是”、“否”，尽可能少的回答“不知道”



# 近似法判断内存泄露





# 非判定问题

- 近似方法、**must**分析和**may**分析的定义取决于问题性质
- 例：假设正确答案是一个集合S
  - **must**分析：返回的集合总是S的子集
  - **may**分析：返回的集合总是S的超集
  - 或者更全面的分析：返回不相交(Disjoint)集合**MUST**,**MAY**,**NEVER**, 其中
    - $MUST \subseteq S$ ,
    - $NEVER \cap S = \emptyset$ ,
    - $S \subseteq MUST \cup MAY$
- **must**和**may**的区分并不严格，可以互相转换
  - 将判定问题取反
  - 对于返回集合的问题，将返回值定义为原集合的补集





# 练习

- 测试属于must分析还是may分析？
- 类型检查属于must分析还是may分析？



# 答案

- 例：利用测试和类型检查回答是否存在输入让程序抛出异常的问题
- 测试：给出若干关键输入，看在这些输入上是否会抛出异常
  - 如果抛出异常，回答“是”
  - 如果没有抛出以后，回答“不知道”
  - must分析
- 类型检查：采用类似Java的函数签名，检查当前函数中所有语句可能抛出的异常都被捕获，并且main函数不允许抛出异常
  - 如果通过类型检查，回答“否”
  - 如果没有通过，回答“不知道”
  - may分析



# 另一个术语：安全性

- 程序分析技术最早源自编译器优化
- 在编译器优化中，我们需要保证决定不改变程序的语义
- 安全性：根据分析结果所做的优化绝对不会改变程序语义
- 安全性的定义和具体应用场景有关，但往往对应于must分析和may分析中的一个
- 安全性有时也被成为健壮性(soundness)、正确性(correctness)
- 健壮性的反面有时也被成为完整性(completeness)
  - 如果健壮性对应must-analysis，则完整性对应may-analysis



# 求近似解基本原则——抽象

- 给定表达式语言

term := term + term  
      | term - term  
      | term \* term  
      | term / term  
      | integer

- 判断结果的符号是正是负

- 限制条件：分析在一台只有一个两位寄存器，没有内存的机器上进行



# 限制条件

- 无限制条件：直接求出表达式的值，然后查看符号位
- 有限制条件：
  - 无法分析出精确的答案
  - 将结果映射到一个可分析的抽象域



# 抽象域

- 正 = {所有的正数}
- 零 = {0}
- 负 = {所有的负数}

- 乘法运算规则:

- 正 \* 正 = 正
- 正 \* 零 = 零
- 正 \* 负 = 负

- 负 \* 正 = 负
- 负 \* 零 = 零
- 负 \* 负 = 正

- 零 \* 正 = 零
- 零 \* 零 = 零
- 零 \* 负 = 零



# 问题

- 正+负=?
- 解决方案：增加抽象符号表示“不知道”
  - 正={所有的正数}
  - 零={0}
  - 负={所有的负数}
  - 躲={所有的整数和NaN}



# 运算举例

+	正	负	零	躲
正	正			
负	躲	负		
零	正	负	零	
躲	躲	躲	躲	躲

/	正	负	零	躲
正	正	负	零	躲
负	负	正	零	躲
零	躲	躲	躲	躲
躲	躲	躲	躲	躲





# 测试和类型检查中的抽象

- 例：利用测试和类型检查回答是否存在输入让程序抛出异常的问题
- 测试：给出若干关键输入，看在这些输入上是否会抛出异常
  - 把程序输入空间抽象成“待测试输入序列”，程序的执行过程分别对于序列中的每一个值计算输出。
- 类型检查：采用类似Java的函数签名，检查当前函数中所有语句可能抛出的异常都被捕获，并且main函数不允许抛出异常
  - 把程序抽象成只包含throw语句、try/catch语句、函数声明和调用的抽象程序，然后在抽象程序上分析



# 本课程 《软件分析技术》

- 给定软件系统，回答关于系统性质的问题的技术，称为软件分析技术
  - 该软件的运行是否会停机？
  - 该软件中是否有内存泄露？
  - 该软件运行到第10行时，指针x会指向哪些内存位置？
  - 该软件中的API调用是否符合规范？

# 课程内容1：基于抽象解释的程序分析



- 数据流分析
  - 如何对分支、循环等控制结构进行抽象
- 过程间分析
  - 如果对函数调用关系进行抽象
- 指针分析
  - 如何对堆上的指向结构进行抽象
- 抽象解释
  - 对于抽象的通用理论
- 抽象解释的自动化

# 课程内容2：基于约束求解的程序分析



- SAT
  - 基础可满足性问题
- SMT
  - 通用可满足性问题
- 霍尔逻辑
  - 表达程序规约的方法和相应推导方法
- 符号执行
  - 基于约束求解的路径敏感分析



# 课程内容3： 软件分析应用

- 程序综合——如何让电脑自动编写程序
- 缺陷定位——确定程序有Bug后，如何知道Bug在哪里
- 缺陷修复——找到Bug后，如何让电脑自动修复程序中的Bug

# 课程内容4： 智能化软件分析



- 前沿内容，介绍该领域的主要问题和一些在探索的方法
- 程序统计方法
- 程序概率推导方法
- 基于元启发式搜索的优化问题求解方法



# 软件分析发展历史

- 软件分析最早随着编译技术一起发展起来
  - 早期的发展主要是基于抽象的技术，强调安全性
- 2000年以后，几个主要变化
  - 编译器越来越成熟，软件分析技术更多用于软件工程工具而非编译器
  - 随着互联网的发展，可用的数据空前增多
  - 计算机速度有了大幅提高，使得很多以前不能做的智能分析成为可能
    - SAT求解算法获得突飞猛进
- 形成了几大新趋势
  - 安全性不再作为第一位强调（Soundness宣言）
  - 基于约束求解的方法大量增多
  - 智能化软件分析蓬勃发展，形成若干子领域
    - 软件仓库挖掘、软件解析学、基于搜索的软件工程



# 为什么要开设《软件分析》

- 重要性
  - 几乎所有的编译优化都离不开软件分析
  - 几乎所有的开发辅助工具都离不开软件分析
  - 更好的理解计算和抽象的本质与方法
- 学习难度
  - 历史长
  - 方法学派多
  - 缺乏易懂的教材
  - 传统上采用大量数学符号





# 为什么要学习《软件分析》

- 大公司核心部门的就业机会
  - 微软、IBM、谷歌、Oracle、Facebook的开发工具部门
  - 大公司的内部工具部门
    - “谷歌最强的人都在开发内部工具。” —某网友
  - 企业研究院
- 中国企业
  - 中国企业已经发展到了需要自己的开发工具的阶段，但仍缺乏合适的人才
  - “目前的白盒工具的市场上，基本都是国外的产品。”  
--HP某售前工程师，2015
  - 华为、阿里、360等企业的软件分析团队每年找我定向推荐
- 科学研究



# 教学团队

- 教师：熊英飞
  - 2009年于日本东京大学获得博士学位
  - 2009-2011年在加拿大滑铁卢大学从事博士后研究
  - 2012年加入北京大学，任“百人计划”研究员
  - 办公室：1431
  - 邮件： [xiongyf@pku.edu.cn](mailto:xiongyf@pku.edu.cn)
- 助教：郜哲
  - 硕士二年级
  - 办公室：1434
  - 邮件： [sonia@pku.edu.cn](mailto:sonia@pku.edu.cn)



# 预备知识

- 编译器前端知识
- 熟悉常见的数学符号



# 课程主页

- <http://sei.pku.edu.cn/~xiongyf04/SA/main.htm>



# 参考书

- 课程课件
- 《编译原理》 Aho等
- 《Lecture notes on static analysis》 Moller and Schwartzbach
  - <https://cs.au.dk/~amoeller/spa/>
- 《Principle of Program Analysis》 Nielson等



# 考核与评分（暂定）

- 课堂表现：20分
- 课程作业：20分
- 课程项目1：30分
- 课程项目2：30分



# 课程项目1

- 感谢唐浩同学帮忙制作开发包和评测平台！
- 实现一个Java上的指针分析系统
- 要求：
  - 无法在测试程序上正常运行的不合格
  - 在测试程序上能输出结果，但结果不健壮(unsound), 60分
  - 结果健壮，根据精度分数在70-100之间
  - 代码提交作为评分参考
- 组队完成：
  - 2-3名同学一个小组
  - 组内贡献不均等的，请在提交的时候说明



# 程序样例

输入程序:

```
public static void main(String[] args) {  
    Benchmark.alloc(1); //标记分配点, 没有标记的默认编号为0  
    A a = new A();  
    Benchmark.alloc(2);  
    A b = new A();  
    Benchmark.alloc(3);  
    A c = new A();  
    if (args.length>1) a=b;  
    Benchmark.test(1, a); //标记测试点编号和被测变量  
    Benchmark.test(2, c);  
}
```

输出:

1: 1 2

2: 3

每行一个测试点, 以测试点编号开头。

冒号后面是可能的分配点, 多个分配点以空格分割





# 开发平台

- Java上常见静态分析平台（自学）：
  - Soot（推荐）
  - WALA
  - Chord
- 部分平台已经自带指针分析，要求
  - 不能直接调用平台的指针分析模块
  - 可以使用平台提供的其他支撑，比如数据流分析框架，控制流图构建，Java语言化简等



# 时间节点和提交内容

- 组队报给助教（10月7日）
- 代码提交（暂定12月1日）
  - Readme.pdf: A4两页以内，描述算法的主要设计思想，小组成员姓名、学号和分工
  - Code目录：项目源代码
  - analyzer.jar: 编译好的jar文件
- 现场报告（暂定12月5日）
  - 各组交流所采用的算法，预计每组10-15分钟左右




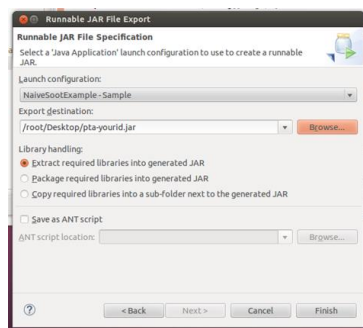
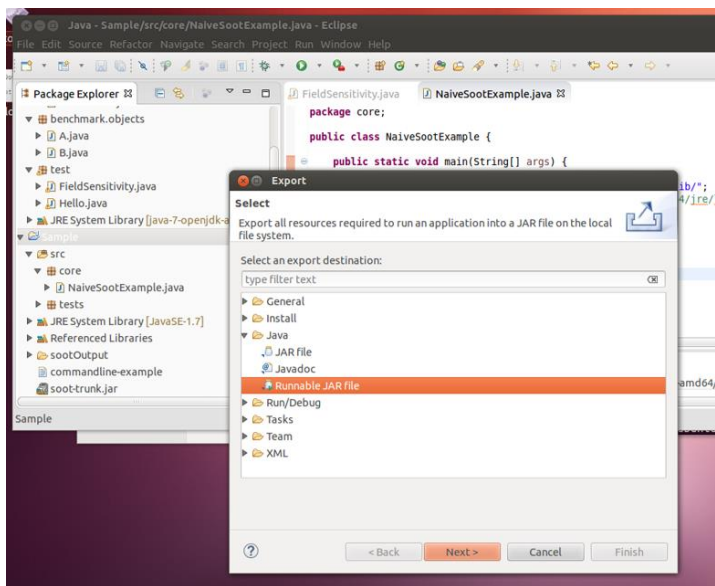
# 测试方法

- `java -jar analyzer.jar [src] [SomePackage.Main]`
  - `[src]`: 程序源码的根目录，同时包括java文件和class文件，并且包括JDK1.7版本的rt.jar和jce.jar（SOOT需要）
  - `[SomePackage.Main]`: 包含main函数的类名
- 输出写到result.txt
- 测试环境：JDK 1.8, Windows或者Linux（请让代码跨平台）

# 导出可执行的jar包（以eclipse为例）



- Jar包需要包括所有dependency





# 课程项目2

- 待定
- 可能题目
  - 实现一个程序综合工具
  - 实现一个约束求解工具



# 教学安排

- 9月
  - 数据流分析
- 10月
  - 过程间分析、指针分析、控制流分析
- 11月
  - 抽象解释、约束求解、符号执行
- 12月
  - 软件分析应用、智能化软件分析
- 项目必备知识至少在截止日期前一月讲完