软件分析

Steensgaard算法和过程间指针分析

熊英飞
北京大学

复习：Anderson指向分析算法填空

赋值语句	约束
a=&b	$\boldsymbol{a} \supseteq \{b\}$
a=b	
a=*b	
*a=b	

复习：Anderson指向分析算法填空

赋值语句	约束
a=&b	$\boldsymbol{a} \supseteq \{b\}$
a=b	$\boldsymbol{a} \supseteq \boldsymbol{b}$
a=*b	$\forall v \in \boldsymbol{b}. \boldsymbol{a} \supseteq \boldsymbol{v}$
*a=b	$\forall v \in \boldsymbol{a}. \boldsymbol{v} \supseteq \boldsymbol{b}$

能不能换成=？

Steensgaard指向分析算法

- Anderson算法的复杂度为$O(n^3)$
  - n为程序中变量的数量
- Steensgaard指向分析通过牺牲精确性来达到效率
- 分析复杂度为$O\big(n\alpha(n)\big)$，接近线性时间。
  - n为程序中的语句数量。
  - α为阿克曼函数的逆
  - $\alpha(2^{132}) < 4$

Steensgaard指向分析算法

- Steensgaard算法把Anderson算法中的超集关系换成等价关系
- 通过不断合并同类项来保证算法在接近线性的时间内完成

Steensgaard指向分析算法

```
o=&v;
q=&p;
if (a > b) {
  p=*q;
  p=o; }
*q=&w;
```

- 产生约束
  - $\mathrm{v} \in \mathbf{o}$
  - $\mathrm{p} \in \mathbf{q}$
  - **p=*q**
  - **p=o**
  - $w \in {}^{*}\boldsymbol{q}$
  - $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

通用约束，用于传递相等关系

- 赋值使得左右两边的集合相等
- 最后一条约束使得相等指针的后继也相等
- 因为集合相等，所以只需要一个集合来表示
- 每个等号约束都是集合的合并

合并操作执行方法

- $v \in \mathbf{o}$
- $p \in \mathbf{q}$
- $\mathbf{p=*q}$
- $\mathbf{p=o}$
- $w \in *\boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

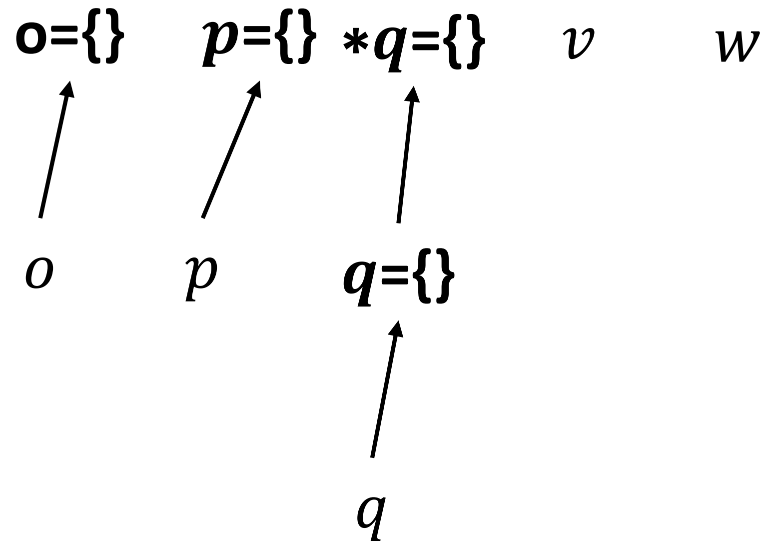

- 边表示指向关系
- 每个元素只能有一个后继
- 如果合并导致多于一个后继，就合并后继

合并操作执行方法

- $v \in \mathbf{o}$
- $p \in \mathbf{q}$
- **p=*q**
- **p=o**
- $w \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

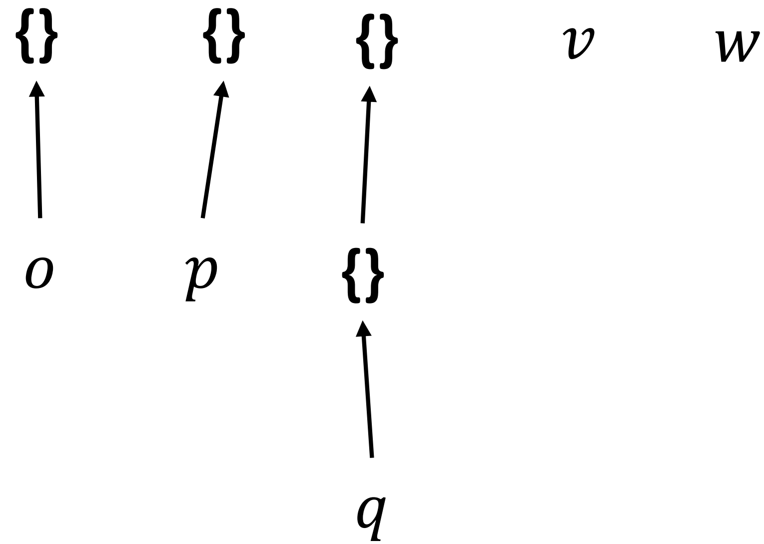

- 边表示指向关系
- 每个元素只能有一个后继
- 如果合并导致多于一个后继，就合并后继

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w\ \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

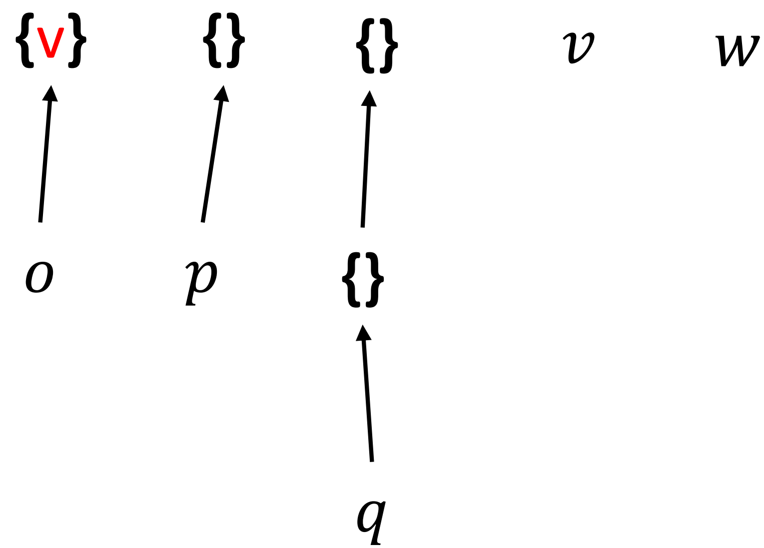

对于集合和元素的合并，添加元素到集合中，并添加元素的后继为集合的后继

合并操作执行方法

- $\mathrm{v} \in \mathbf{o}$
- $\mathrm{p} \in \mathbf{q}$
- **p=*q**
- **p=o**
- $w \in^{*} \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =_{*} \boldsymbol{y}$

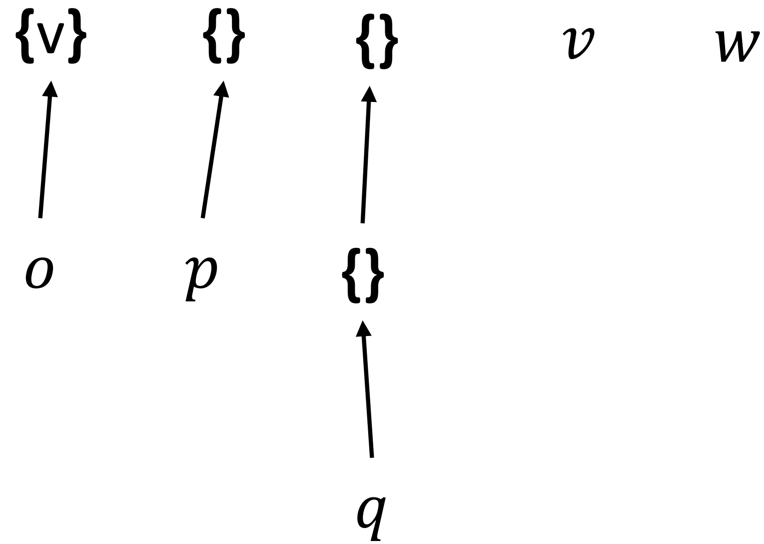

对于集合和元素的合并，添加元素到集合中，并添
加元素的后继为集合的后继

合并操作执行方法

- $\mathrm{v} \in \mathbf{o}$
- $\mathrm{p} \in \mathbf{q}$
- **p=*q**
- **p=o**
- $w \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

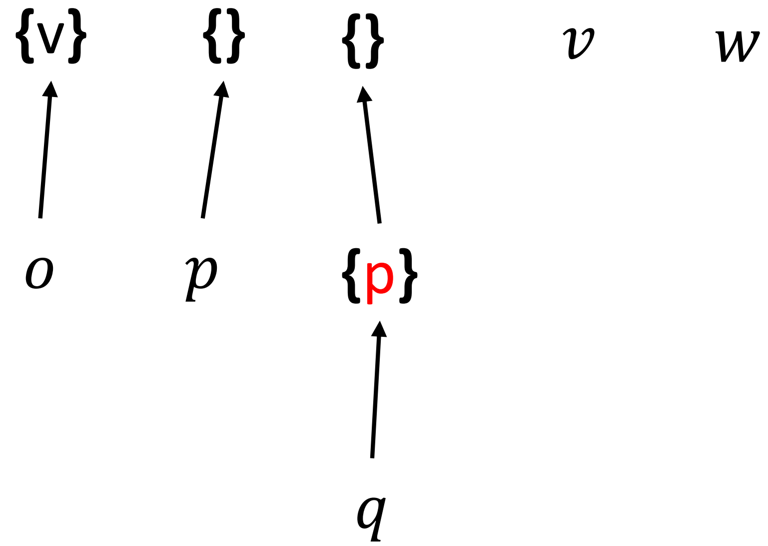

对于集合和元素的合并，添加元素到集合中，并添加元素的后继为集合的后继

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =_* \boldsymbol{y}$

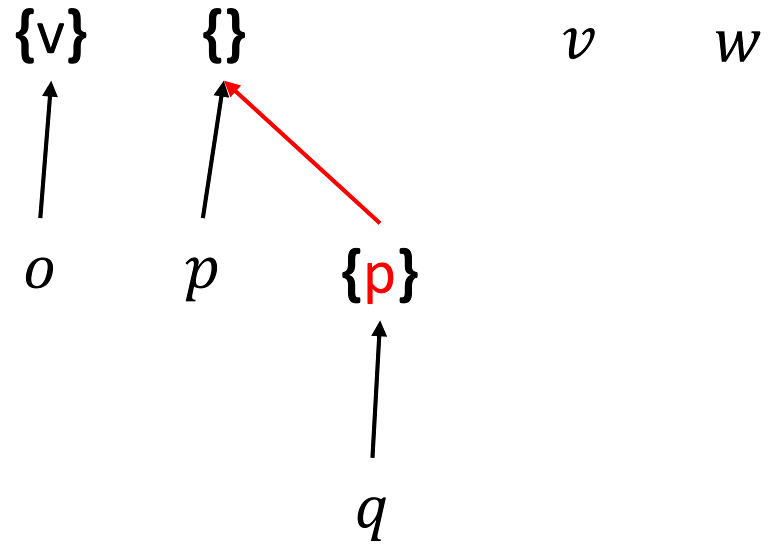

继续合并后继

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w \in^{*} \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =_{*} \boldsymbol{y}$

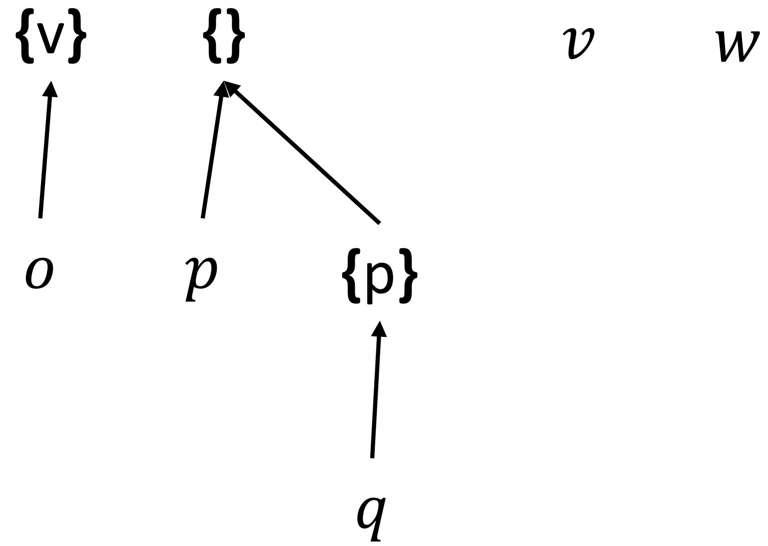

对于集合的合并，直接合并两个集合

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w\ \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

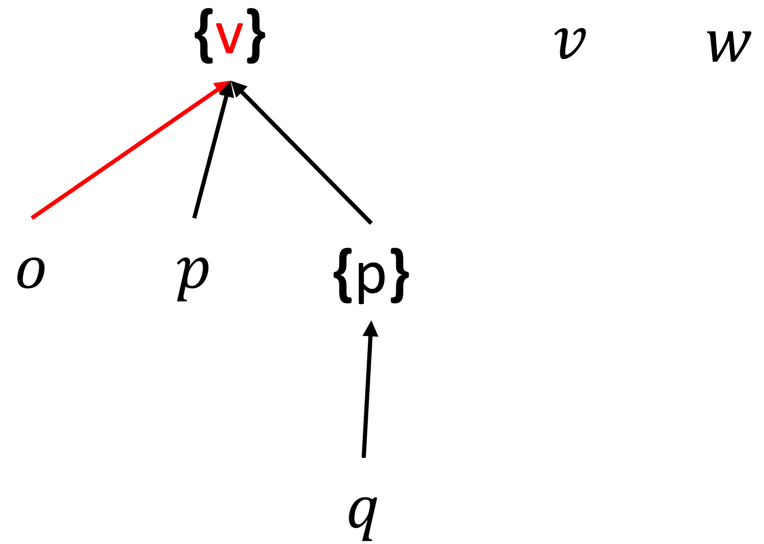

对于集合的合并，直接合并两个集合

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w\ \in^{*}\boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =* \boldsymbol{y}$

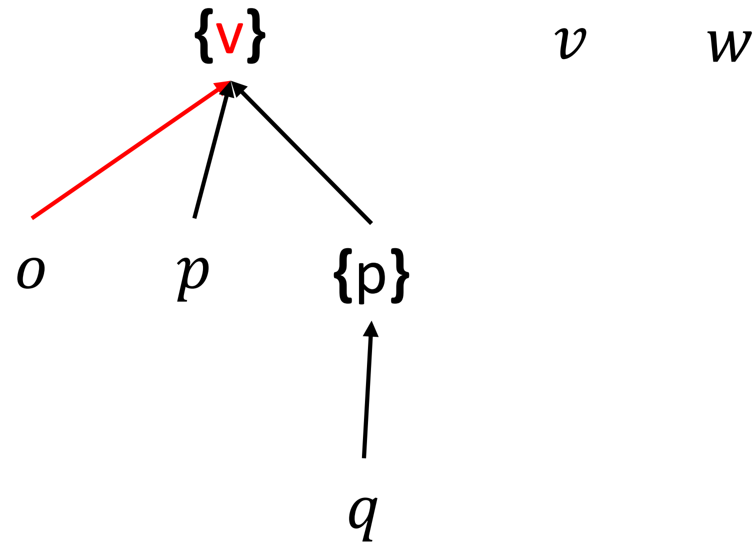

对于集合的合并，直接合并两个集合

合并操作执行方法

- v ∈ **o**
- p ∈ **q**
- **p=*q**
- **p=o**
- $w \in^* \boldsymbol{q}$
- $\forall y. \forall x \in \boldsymbol{y}. \boldsymbol{x} =_* \boldsymbol{y}$

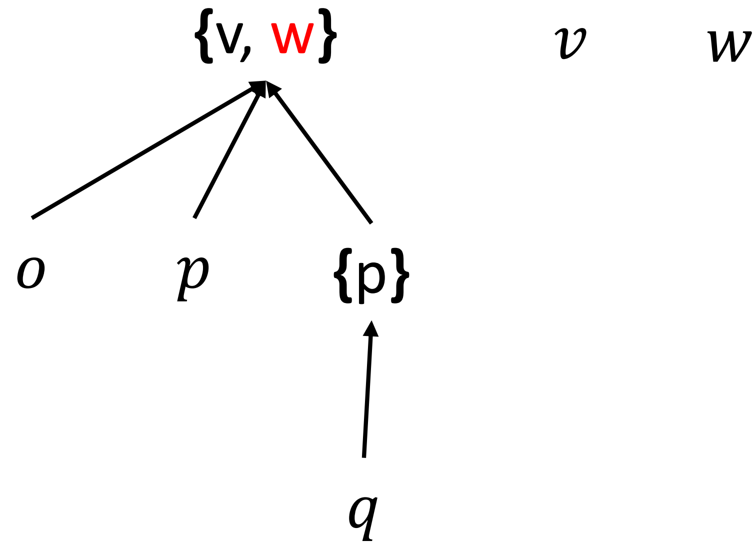

- 返回
  - $\boldsymbol{p} = \{v, w\}$
  - $\boldsymbol{q} = \{p\}$
  - $\boldsymbol{o} = \{v, w\}$ //不精确

复杂度分析

- 节点个数为$O(n)$
- 每次合并会减少一个节点，所以总合并次数是$O(n)$
- 每次合并的时间开销包括
  - 集合的合并开销
  - 解析*p等指针引用找到合适集合的开销
- 通过选择合适的数据结构（union-find structure），可以做到O(1)时间的合并和$O(\alpha(n))$的查找

术语

- Inclusion-based
  - 指类似Anderson方式的指针分析算法
- Unification-based
  - 指类似Steensgaard方式的指针分析算法

别名分析

- 给定两个变量a, b，判断这两个变量是否指向相同的内存位置，返回以下结果之一
  - a, b是must aliases：始终指向同样的位置
  - a, b是must-not aliases：始终不指向同样的位置
  - a, b是may aliases: 可能指向同样的位置，也可能不指向
- 别名分析结果可以从指向分析导出
  - 如果**a=b**且|**a**|=1，则a和b为must aliases
  - 如果**a**∩**b**=∅，则a和b为must-not aliases
  - 否则a和b为may aliases
- 别名分析本身有更精确的算法，但实践中常直接从指向分析导出

上下文敏感的指针分析

- 能否做精确的上下文敏感的指针分析？
- 域敏感的指针分析或者考虑二级指针的分析：不能
- 简单理论理解
  - 上下文无关性是一个上下文无关属性
    - 必须用下推自动机表示
  - 域敏感性也是一个上下文无关属性
  - 两个上下文无关属性的交集不一定是上下文无关属性
- Tom Reps等人2000年证明这是一个不可判定问题

解决方法

- 降低上下文敏感性：把被调方法根据上下文克隆n次
- 降低域敏感性：把域展开n次

复习：基于CFL可达性的域敏感分析

```
y = new B();
m=new A();
x=y;
y.f=m;
n=x.f;
```

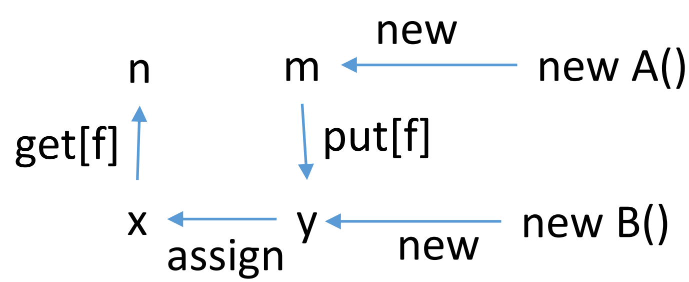

图上的每条边f同时存在反向边$\underline{f}$

FlowTo= new (assign | put[f] Alias get[f])*
PointsTo = ($\underline{\text{assign}}$ | $\underline{\text{get[f]}}$ Alias $\underline{\text{put[f]}}$)* $\underline{\text{new}}$
Alias = PointsTo FlowTo

以下文法安全吗？精确吗？

1. FlowTo = new FlowTo’
   FlowTo’ = put[f] FlowTo’ get[f]
   | FlowTo’ FlowTo’ | assign | ϵ
2. FlowTo= new (Alias | put[f] Alias get[f])*
   PointsTo = (Alias | $\underline{\text{get[f]}}$ Alias $\underline{\text{put[f]}}$)* $\underline{\text{new}}$
   Alias = PointsTo FlowTo | assign | $\underline{\text{assign}}$

降低上下文敏感性

FlowTo= new (assign | put[f] Alias get[f])*
PointsTo = (assign | get[f] Alias put[f])* new
Alias = PointsTo FlowTo

```
Main(): //0
y = new A();//a1
m=new A();//a2
SetF(m, y) //1
x=y;
SetF(y, m) //2
n=x.f;

SetF(a, b):
a.f=b;
```

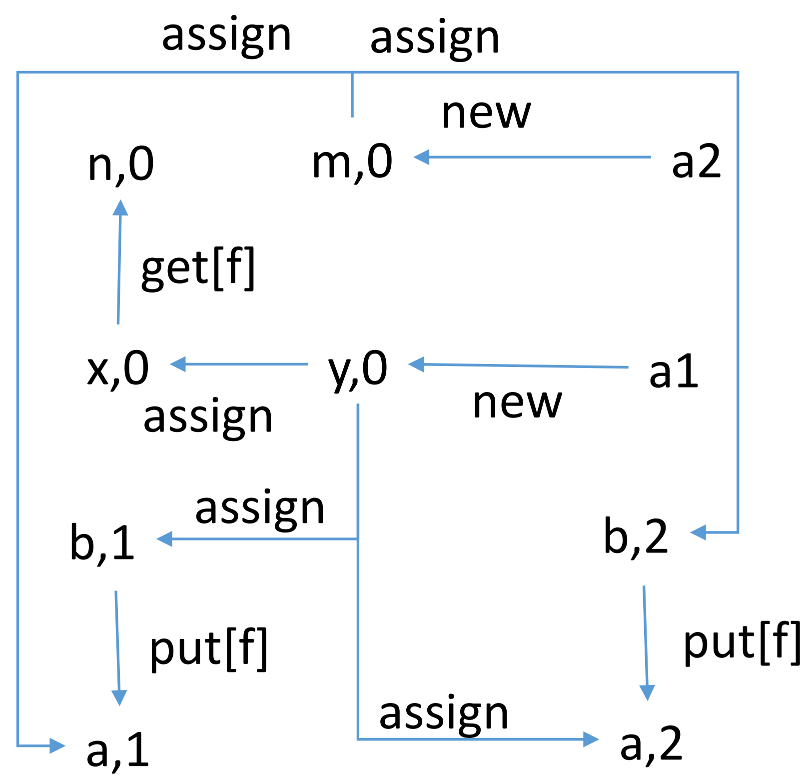

如果不克隆方法，会认为n指向a1

域展开一次

```
Struct Node {
  int value;
  Node* next;
};
a = malloc();
a->next = b;
```

- 对于每个Node*的变量a，创建两个指针变量
  - **a**
  - **a->next**
- a=b产生
  - **a ⊇ b**
  - **a->next = b->next**
- a->next=b产生
  - **a->next ⊇ b**
  - **a->next = b->next**
- a=b->next产生
  - **a ⊇ b->next**
  - **a->next = b->next**

能不能换成⊇

约束中不含全程量词，可以用IFDS转成图并加上括号。

域展开两次

```
Struct Node {
  int value;
  Node* next;
};
a = malloc();
a->next = b;
```

- 对于每个Node*的变量a，创建两个指针变量
  - **a**
  - **a->next**
  - **a->next->next**
- a->next=b产生
  - **a->next $\supseteq$ b**
  - **a->next->next $=$ b->next**
  - **a->next->next $=$ b->next->next**
- a=b->next产生
  - **a $\supseteq$ b->next**
  - **a->next $=$ b->next->next**
  - **a->next->next $=$ b->next->next**

过程间分析-函数指针

```
interface I {
  void m();
}
class A implements I {
  void m() { x = 1; }
}
class B implements I {
  void m() { x = 2; }
}
static void main() {
   I i = new A();
   i.m();
}
```

如何设计分析算法得出程序执行结束后的x所有可能的值？

控制流分析

- 确定函数调用目标的分析叫做控制流分析
- 控制流分析是may analysis
  - 为什么不是must analysis?
- 控制流分析 vs 数据流分析
  - 控制流分析确定程序控制的流向
  - 数据流分析确定程序中数据的流向
  - 数据流分析在控制流图上完成，因此控制流分析是数据流分析的基础

Class Hierarchy Analysis

```
interface I {
  void m(); }
class A implements I {
  void m() { x = 1; } }
class B implements I {
  void m() { x = 2; } }
static void main() {
   I i = new A();
   i.m(); }
class C { void m() {} }
```

- 根据i的类型确定m可能的目标
- 在这个例子中，i.m可能的目标为
  - A.m()
  - B.m()
- 不可能的目标为
  - C.m()
- 分析结果为x={1,2}
- 优点：简单快速
- 缺点：非常不精确，特别是有Object.equals()这类调用的时候

Rapid Type Analysis

```
interface I {
  void m(); }
class A implements I {
  void m() { x = 1; } }
class B implements I {
  void m() { x = 2; } }
static void main() {
   I i = new A();
   i.m(); }
class C { void m() {
  new B().m();
} }
```

- 只考虑那些在程序中创建了的对象
- 可以有效过滤library中的大量没有使用的类

Rapid Type Analysis

```
interface I {
  void m(); }
class A implements I {
  void m() { x = 1; } }
class B implements I {
  void m() { x = 2; } }
static void main() {
   I i = new A();
   i.m(); }
class C { void m() {
  new B().m();
} }
```

- 三个集合
  - 程序中可能被调用的方法集合Methods，初始包括main
  - 程序中所有的方法调用和对应目标Calls→Methods
  - 程序中所有可能被使用的类Classes
- Methods中每增加一个方法
  - 将该方法中所有创建的类型加到Classes
  - 将该方法中所有的调用加入到Call，目标初始为根据当前Classes集合类型匹配的方法
- Classes中每增加一个类
  - 针对每一次调用，如果类型匹配，把该类中对应的方法加入到Calls→Methods
  - 把方法加入到Methods当中

分析结果i.m()调用A.m()

Rapid Type Analysis

```
interface I {
  void m(); }
class A implements I {
  void m() { x = 1; } }
class B implements I {
  void m() { x = 2; } }
static void main() {
   I i = new A();
   I j = new B();
   i.m(); }
class C { void m() {
  new B().m();
} }
```

- 分析速度非常快
- 精度仍然有限
- 在左边的例子中，得出i.m的目标包括A.m和B.m
- 如何进一步分析出精确的结果？

精确的控制流分析CFA

- 该算法没有名字，通常直接称为CFA (control flow analysis)
- CFA和指针分析需要一起完成
  - 指针分析确定调用对象
  - 调用对象确定新的指向关系
- 原始算法定义在λ演算上
- 这里介绍算法的面向对象版本

CFA-算法

```
interface I {
  I m(); }
class A implements I {
  I m() { return new B(); } }
class B implements I {
  I m() { return new A(); } }
static void main() {
   I i = new A();
   if (...) i = i.m();
   I x = i.m();
}
```

- 首先每个方法的参数和返回值都变成图上的点
  - 注意this指针是默认参数
- 对于方法调用

```
f() {...
  x = y.g(a, b)
...}
```

根据调用对象和方法名确定被调用方法

方法的声明类

- 生成约束
  - $\forall y \in \mathbf{f\#y}.\ \forall m \in \mathrm{targets}(y, g),$
    $\mathbf{f\#x} \supseteq \mathbf{m\#ret}$
    $\mathbf{m\#this} \supseteq \mathrm{filter}\ (\mathbf{f\#y}, \mathrm{declared}(m))$
    $\mathbf{m\#a} \supseteq \mathbf{f\#a}$
    $\mathbf{m\#b} \supseteq \mathbf{f\#b}$
- 约束求解方法和Anderson指针分析算法类似

保留符合特定类型的对象

CFA-计算示例

```
interface I {
  I f(); }
class A implements I {
  I f() { return new B¹(); } }
class B implements I {
  I f() { return new A²(); } }
static void main() {
   I i = new A³();
   if (...) i = i.f();
   I x = i.f();
}
```

- **main#i** $\supseteq$\{3\}
- $\forall i \in$ **main#i**, $\forall m \in$ targets(i, f),
  - **main#i**$\supseteq$**m#ret**
  - $\mathbf{m\#this} \supseteq$ $\text{filter}(\mathbf{main\#i}, \text{declared}(\text{m}))$
- $\forall i \in$ **main#i**, $\forall m \in$ targets(i, f),
  - **main#x**$\supseteq$**m#ret**
  - $\mathbf{mthis} \supseteq \text{filter}\left(\mathbf{main\#i}, \text{declared}(\text{m})\right)$
- **A.f#ret** $\supseteq$\{1\}
- **B.f#ret** $\supseteq$\{2\}
-
- 求解结果
  - **main#i**=\{1,2,3\}
  - **main#x**=\{1, 2\}

CFA

- 以上CFA算法是否是上下文敏感的？
- 不是，因为每个方法只记录了一份信息，没有区分上下文
- 用克隆的方法处理上下文敏感性
- 基于克隆方法的CFA也被称为m/k-CFA
  - 上下文不敏感的CFA称为0-CFA

流敏感vs上下文敏感

- 当不能同时做到两种精度时，优先考虑哪个？
  - 通常认为，在C语言等传统命令式语言中流敏感性比较重要
  - 在Java、C++等面向对象语言中上下文敏感性比较重要
  - 主流指针分析算法通常时上下文敏感而流非敏感的

Soot

- Java环境需求：Java 8（下载页：https://www.oracle.com/technetwork/java/javase/downloads/index.html ）
- Soot下载：（https://soot-build.cs.uni-paderborn.de/public/origin/master/soot/soot-master/3.1.0/build/sootclasses-trunk-jar-with-dependencies.jar ）
- 一个顺手的Java开发环境（演示会使用Intellij IDEA）